

Kamień milowy 2

Daria Bartkowiak, Oliwia Wójcicka, Karolina Kawulska

Maj 2026

1 Model hurtowni danych, atrybuty i miary

W ramach projektu przygotowano fizyczny model hurtowni danych w SQL Server Management Studio. Model ma strukturę typu **snowflake**, ponieważ oprócz tabeli faktów i wymiarów występuje także relacja pomiędzy wymiarami **DimSensor** oraz **DimLocation**. Sensor jest przypisany do konkretnej lokalizacji, dlatego lokalizacja została wydzielona jako osobna tabela wymiaru.

Centralną tabelą modelu jest **FactPedestrianCount**, ponieważ przechowuje ona właściwe dane pomiarowe, czyli liczbę pieszych zarejestrowanych przez sensor w konkretnej dacie i godzinie. Pozostałe tabele opisują kontekst tego pomiaru: czas, datę, sensor, lokalizację oraz pogodę.



Rysunek 1: Fizyczny model hurtowni danych typu snowflake

1.1 Opis tabel

W modelu utworzono jedną tabelę faktów oraz pięć tabel wymiarów:

- **FactPedestrianCount** – tabela faktów przechowująca liczbę pieszych,

- **DimDate** – wymiar daty, umożliwiający analizę według dnia, miesiąca, kwartału, roku i dnia tygodnia,
- **DimTime** – wymiar czasu, umożliwiający analizę według godziny i pory dnia,
- **DimSensor** – wymiar sensora, opisujący sensor, jego status, nazwę i kierunki pomiaru,
- **DimLocation** – wymiar lokalizacji, opisujący nazwę lokalizacji, współrzędne, obszar i ulicę,
- **DimWeather** – wymiar pogody, zawierający temperaturę, opady, zachmurzenie, wiatr oraz kod pogody.

Dla tabel określono typy danych, takie jak `int`, `bigint`, `date`, `time`, `datetime2`, `varchar`, `decimal` i `bit`. Każda tabela posiada klucz główny, a tabela faktów zawiera klucze obce prowadzące do wymiarów.

1.2 Relacje w modelu

Tabela `FactPedestrianCount` jest połączona z wymiarami przez klucze obce:

- z `DimDate` przez `DateKey`,
- z `DimTime` przez `TimeKey`,
- z `DimSensor` przez `SensorKey`,
- z `DimLocation` przez `LocationKey`,
- z `DimWeather` przez `WeatherKey`.

Dodatkowo `DimSensor` jest połączona z `DimLocation`, ponieważ każdy sensor działa w określonej lokalizacji. Dzięki temu model pozwala analizować ruch pieszy według czasu, miejsca, sensora oraz warunków pogodowych.

1.3 Wartości NULL i NOT NULL

W modelu nie dopuszczono wartości NULL w tabelach hurtowni danych. Wszystkie klucze, pola techniczne i atrybuty opisowe zostały oznaczone jako `NOT NULL`. Brakujące dane są obsługiwane za pomocą wartości technicznych, dzięki czemu rekordy mogą zostać poprawnie zapisane i połączone z innymi tabelami.

Dla pól tekstowych, takich jak status sensora, kierunek pomiaru, nazwa obszaru czy ulica, zastosowano wartość `Unknown`. Oznacza ona, że dana informacja nie była dostępna w źródle. Dla pól liczbowych przyjęto wartości techniczne, np. 0 albo -1, zależnie od znaczenia pola.

Dla pól dat zastosowano specjalne daty techniczne. Data `1900-01-01` oznacza brak znanej daty początkowej, natomiast `9999-12-31` oznacza brak daty końcowej albo rekord nadal obowiązujący. Dlatego w mechanizmie SCD2 aktualny rekord ma `ValidTo` = `9999-12-31` oraz `IsCurrent` = 1. Jeżeli rekord przestaje być aktualny, kolumna `ValidTo` otrzymuje rzeczywistą datę zakończenia, a `IsCurrent` zostaje ustawione na 0.

1.4 Obsługa SCD Type 2

Najważniejszym elementem modelu jest obsługa zmienności wymiarów typu **SCD Type 2**. Zastosowano ją dla tabel **DimSensor** oraz **DimLocation**, ponieważ dane o sensorach i lokalizacjach mogą zmieniać się w czasie. Sensor może zostać przeniesiony, wyłączony, usunięty albo może zmienić status. Zmianie mogą też ulec dane lokalizacyjne.

W tabelach **DimSensor** i **DimLocation** dodano trzy kolumny techniczne:

- **ValidFrom** – data rozpoczęcia obowiązywania danej wersji rekordu,
- **ValidTo** – data zakończenia obowiązywania danej wersji rekordu,
- **IsCurrent** – informacja, czy rekord jest aktualną wersją.

SCD2 działa w ten sposób, że zmiany w danych nie nadpisują starego rekordu. Jeśli na przykład sensor zmieni status albo lokalizację, poprzedni rekord zostaje zamknięty przez uzupełnienie kolumny **ValidTo** i ustawienie **IsCurrent** = 0. Następnie dodawany jest nowy rekord z aktualnymi danymi, z ustawionym **ValidFrom**, pustym **ValidTo** oraz **IsCurrent** = 1.

Dzięki temu zachowana jest historia zmian. Jest to ważne, ponieważ wcześniejsze pomiary powinny być analizowane według starego stanu sensora lub lokalizacji, a nowe pomiary według aktualnego stanu. W ten sposób model pozwala poprawnie analizować dane historyczne.

1.5 Miary i atrybuty

Główną miarą w modelu jest **PedestrianCount**, czyli liczba pieszych zarejestrowanych przez sensor w danej godzinie. Na tej podstawie można obliczyć:

- sumę liczby pieszych,
- średnią liczbę pieszych,
- maksymalną liczbę pieszych w godzinie,
- minimalną liczbę pieszych w godzinie,
- liczbę aktywnych sensorów,
- zmianę procentową miesiąc do miesiąca,
- zmianę procentową rok do roku.

Najważniejsze atrybuty analityczne to data, godzina, dzień tygodnia, miesiąc, rok, status sensora, nazwa lokalizacji, współrzędne geograficzne, temperatura, opady, zachmurzenie oraz prędkość wiatru.

Przygotowany model spełnia wymagania tej części projektu, ponieważ zawiera model fizyczny hurtowni, tabelę faktów, tabele wymiarów, typy danych, wymagalność kolumn, klucze główne i obce, relacje, obsługę SCD2 oraz opis podstawowych miar i atrybutów.

2 Przetwarzanie ETL, orkestracja i STTM

Proces ETL został przygotowany jako oddzielna warstwa przetwarzania danych pomiędzy źródłami danych a hurtownią danych. Do realizacji procesu wykorzystano SQL Server Integration Services, natomiast dane docelowe zostały załadowane do bazy Microsoft SQL Server. Proces obejmował pobranie danych źródłowych, załadowanie ich do warstwy staging, wykonanie walidacji i czyszczenia danych, obsługę błędów, załadowanie tabel wymiarów oraz finalne załadowanie tabeli faktów.

W projekcie wykorzystano dwa główne źródła danych: plik CSV zawierający godzinowe zliczenia pieszych oraz plik CSV zawierający informacje o sensorach i lokalizacjach. Dane pogodowe zostały przewidziane jako dodatkowe źródło danych, które może zostać zintegrowane z modelem przez wymiar `DimWeather`. W obecnej wersji procesu tabela faktów została załadowana bez danych pogodowych, dlatego pole `WeatherKey` pozostaje puste.

2.1 Źródła danych

W procesie ETL wykorzystano następujące źródła danych:

- `pedestrian_counts.csv` – plik zawierający godzinowe zliczenia pieszych,
- `sensor_locations.csv` – plik zawierający informacje o sensorach i ich lokalizacjach,
- dane pogodowe z API – źródło przewidziane do integracji z wymiarem pogody.

Plik ze zliczeniami pieszych zawiera między innymi identyfikator lokalizacji sensora, datę pomiaru, godzinę oraz łączną liczbę pieszych. Plik z lokalizacjami sensorów zawiera między innymi identyfikator lokalizacji, nazwę sensora, status, opis lokalizacji oraz współrzędne geograficzne.

2.2 Warstwa staging

Przed załadowaniem danych do hurtowni utworzono warstwę staging w schemacie `stg`. Jej zadaniem było tymczasowe przechowywanie danych źródłowych przed wykonaniem transformacji oraz walidacji jakości danych.

Wykorzystano następujące tabele staging:

Tabela 1: Tabele warstwy staging

Tabela	Opis
<code>stg.PedestrianCountsRaw</code>	Surowe dane o godzinowych zliczeniach pieszych.
<code>stg.SensorLocationsRaw</code>	Surowe dane o sensorach i lokalizacjach.
<code>stg.EtlErrors</code>	Tabela przechowująca informacje o błędnych rekordach wykrytych podczas ETL.

Dane w warstwie staging zostały zapisane głównie jako wartości tekstowe. Takie podejście pozwoliło uniknąć błędów podczas początkowego ładowania plików CSV i umożliwiło wykonanie właściwych konwersji dopiero w dalszym etapie procesu ETL.


2.3 Opis procesu ETL w SSIS

Proces ETL został zrealizowany w SQL Server Integration Services. W pakiecie SSIS przygotowano osobne przepływy danych dla pliku ze zliczeniami pieszych oraz dla pliku z lokalizacjami sensorów.


Dla pliku `pedestrian_counts.csv` przygotowano przepływ:

Flat File Source → Data Conversion → OLE DB Destination

Dane zostały załadowane do tabeli `stg.PedestrianCountsRaw`. W trakcie ładowania wykonano konwersję wybranych kolumn do typu tekstowego Unicode. Dla pliku `sensor_locations.csv` zastosowano analogiczny przepływ, który zasilił tabelę `stg.SensorLocationsRaw`.



Rysunek 2: Przepływ SSIS ładujący dane zliczeń pieszych do warstwy staging



Rysunek 3: Przepływ SSIS ładujący dane lokalizacji sensorów do warstwy staging

2.4 Czyszczenie i transformacje danych

Po załadowaniu danych do warstwy staging wykonano walidację oraz transformacje danych. W przypadku danych o zliczeniach pieszych sprawdzono poprawność daty, godziny, identyfikatora sensora oraz liczby pieszych. Liczba pieszych musiała być wartością liczbową większą lub równą zero.

Dla danych lokalizacji sensorów wykonano walidację współrzędnych geograficznych. Wykryto rekordy, w których wartości w kolumnach `LatitudeText` lub `LongitudeText` nie mogły zostać przekonwertowane do typu liczbowego. Przykładowo w kolumnie `LatitudeText` występowały wartości tekstowe, takie jak `West` lub `South`. Oznaczało to przesunięcie danych w kolumnach pliku CSV albo niepoprawny format rekordu.

Do dalszego ładowania wymiaru lokalizacji wykorzystano wyłącznie rekordy, dla których współrzędne geograficzne mogły zostać poprawnie przekonwertowane do typu `DECIMAL`.

2.5 Obsługa błędów

Rekordy niespełniające reguł jakości danych zostały zapisane w tabeli `stg.EtlErrors`. W przypadku danych lokalizacji sensorów wykryto 26 błędnych rekordów. Błędy dotyczyły głównie niepoprawnych wartości współrzędnych geograficznych lub przesunięcia danych w kolumnach pliku CSV.

Tabela 2: Wynik obsługi błędów ETL

Rodzaj danych	Liczba błędnych rekordów
Lokalizacje sensorów	26

Zastosowanie tabeli błędów pozwala zachować informacje o odrzuconych rekordach i jednocześnie nie blokuje dalszego ładowania poprawnych danych do hurtowni.

2.6 Ładowanie wymiarów

Po oczyszczeniu danych wykonano ładowanie tabel wymiarów w schemacie **dw**. Jako pierwsze załadowano wymiary **DimLocation** oraz **DimSensor**, ponieważ tabela faktów wymaga kluczy tych wymiarów.

Tabela **DimLocation** została załadowana wyłącznie poprawnymi rekordami z tabeli **stg.SensorLocation**. W trakcie ładowania wykonano konwersję współrzędnych geograficznych do typu **DECIMAL**. Brakujące wartości opisowe zostały zastąpione wartością techniczną **Unknown**.

Tabela **DimSensor** została załadowana na podstawie danych sensorów oraz powiązana z tabelą **DimLocation** za pomocą klucza **LocationKey**. Dzięki temu każdy sensor został przypisany do odpowiedniej lokalizacji.

Następnie załadowano wymiary czasu i daty. Tabela **DimDate** została zasilona unikalnymi datami ze stagingu, natomiast tabela **DimTime** została zasilona godzinami od 0 do 23.

2.7 Ładowanie tabeli faktów

Po załadowaniu wymiarów wykonano ładowanie tabeli faktów **dw.FactPedestrianCount**. Dane faktów pochodziły z tabeli **stg.PedestrianCountsRaw**. Podczas ładowania tabela faktów została połączona z wymiarami:

- **dw.DimDate** przez datę pomiaru,
- **dw.DimTime** przez godzinę pomiaru,
- **dw.DimSensor** przez identyfikator sensora,
- **dw.DimLocation** przez lokalizację przypisaną do sensora.

Główną miarą ładowaną do tabeli faktów jest **PedestrianCount**, czyli liczba pieszych zarejestrowanych przez sensor w danej godzinie. Kolumna **WeatherKey** pozostała pusta, ponieważ dane pogodowe są przewidziane jako dodatkowe źródło danych i mogą zostać dołączone w kolejnym etapie rozwoju projektu.

2.8 Wyniki końcowego ładowania

Po wykonaniu procesu ETL uzyskano następujące liczby rekordów w tabelach staging, wymiarach oraz tabeli faktów:

Tabela 3: Liczba rekordów po wykonaniu procesu ETL

Tabela	Liczba rekordów
dw.DimSensor	111
dw.DimTime	24
stg.PedestrianCountsRaw	5910180
stg.SensorLocationsRaw	145
stg.EtlErrors	26
dw.DimLocation	111
dw.DimDate	730
dw.FactPedestrianCount	1156794

2.9 Kontrola jakości danych

Po załadowaniu tabeli faktów wykonano kontrolę jakości danych. Sprawdzono, czy w kluczowych kolumnach tabeli dw.FactPedestrianCount występują braki oraz czy miara PedestrianCount nie zawiera wartości ujemnych.

Tabela 4: Kontrola jakości tabeli faktów

Kontrola	Liczba błędów
Brak DateKey	0
Brak TimeKey	0
Brak SensorKey	0
Brak LocationKey	0
Brak PedestrianCount	0
Ujemny PedestrianCount	0

Dodatkowo sprawdzono występowanie duplikatów w tabeli faktów na poziomie kombinacji DateKey, TimeKey, SensorKey oraz LocationKey. Po finalnym ładowaniu nie wykryto duplikatów.

2.10 Harmonogram odświeżania

Tabela 5: Harmonogram odświeżania danych

Element procesu	Częstotliwość
Zliczenia pieszych	Miesięcznie
Lokalizacje sensorów	Miesięcznie
Dane pogodowe	Miesięcznie, opcjonalnie częściej
Wymiary DimDate i DimTime	Po załadowaniu staging
Wymiary DimLocation i DimSensor	Po załadowaniu danych lokalizacji
Tabela faktów	Po załadowaniu wymiarów
Tabela błędów stg.EtlErrors	Przy każdym uruchomieniu ETL
Archiwizacja plików	Po poprawnym przebiegu ETL

Zliczenia pieszych oraz lokalizacje sensorów zaplanowano do odświeżania miesięcznego, ponieważ dane źródłowe z portalu Melbourne są aktualizowane cyklicznie. Dane pogodowe

również mogą być pobierane miesięcznie, aby dopasować je do danych o ruchu pieszym, chociaż technicznie możliwe jest częstsze pobieranie. Wymiary są ładowane przed tabelą faktów, ponieważ tabela faktów korzysta z ich kluczy. Tabela błędów jest uzupełniana przy każdym uruchomieniu ETL, a poprawnie przetworzone pliki mogą być przenoszone do archiwum.

2.11 STTM – Source to Target Mapping

W projekcie przygotowano tabelę STTM, czyli Source-to-Target Mapping. Tabela ta opisuje mapowanie pól źródłowych do tabel staging oraz tabel docelowych hurtowni danych. W tabeli `stg.STTM` zapisano 23 reguły mapowania.

Tabela 6: Uprozczone mapowanie Source-to-Target Mapping

Źródło	Pole źródłowe	Tabela docelowa	Pole docelowe	Transformacja
pedestrian_counts.csv	Location_ID	dw.DimSensor	SensorBusinessKey	Konwersja do typu INT.
pedestrian_counts.csv	Sensing_Date	dw.DimDate	DateKey	Konwersja daty do formatu YYYYMMDD.
pedestrian_counts.csv	Sensing_Date	dw.DimDate	FullDate	Konwersja do typu DATE.
pedestrian_counts.csv	HourDay	dw.DimTime	TimeKey	Utworzenie klucza czasu w formacie HH00.
pedestrian_counts.csv	Total_of_Directions	dw.FactPedestrianCount	PedestrianCount	Konwersja do typu INT, walidacja wartości większej lub równej zero.
sensor_locations.csv	Location_ID	dw.DimLocation	LocationBusinessKey	Przeniesienie identyfikatora lokalizacji jako klucza biznesowego.
sensor_locations.csv	Sensor_Description	dw.DimLocation	LocationName	Braki danych zastępowane wartością Unknown.
sensor_locations.csv	Latitude	dw.DimLocation	Latitude	Konwersja do typu DECIMAL; błędne rekordy trafiają do <code>stg.EtlErrors</code> .
sensor_locations.csv	Longitude	dw.DimLocation	Longitude	Konwersja do typu DECIMAL; błędne rekordy trafiają do <code>stg.EtlErrors</code> .
sensor_locations.csv	Sensor_Name	dw.DimSensor	SensorName	Braki danych zastępowane wartością Unknown.
sensor_locations.csv	Status	dw.DimSensor	SensorStatus	Przeniesienie statusu sensora, obsługa zmian przez SCD2.
ETL technical	data ładowania	dw.DimSensor, dw.DimLocation	ValidFrom	Ustawienie daty rozpoczęcia obowiązywania wersji rekordu.
ETL technical	brak	dw.DimSensor, dw.DimLocation	ValidTo	Wartość NULL dla aktualnej wersji rekordu.
ETL technical	brak	dw.DimSensor, dw.DimLocation	IsCurrent	Wartość 1 dla aktualnej wersji rekordu.

3 Koncepcja raportowania

3.1 Powiązanie raportów z celem biznesowym

Zaprojektowana koncepcja raportowania bezpośrednio odpowiada na cele biznesowe zdefiniowane na początku projektu. Przygotowane dashboardy dostarczą władzom miasta Melbourne oraz planistom przestrzennym interaktywnych narzędzi do monitorowania natężenia ruchu pieszego. Umożliwią one identyfikację najbardziej obciążonych obszarów, analizę zachowań pieszych w kontekście pór dnia, dni tygodnia i sezonowości, a także weryfikację wpływu warunków atmosferycznych na wykorzystanie przestrzeni miejskiej. Dzięki temu możliwe będzie podejmowanie decyzji opartych na danych w zakresie planowania infrastruktury, zarządzania ruchem oraz organizacji wydarzeń masowych.

3.2 Weryfikacja osiągalności raportów na podstawie modelu

Zaproponowane raporty są w pełni osiągalne na podstawie fizycznego modelu hurtowni danych przygotowanego w fazie modelowania.

- Wymiary `DimDate` i `DimTime` w połączeniu z tabelą faktów `FactPedestrianCount` pozwalają na dowolne agregacje czasowe oraz identyfikację szczytów komunikacyjnych.
- Wymiary `DimLocation` i `DimSensor` dostarczają precyzyjnych współrzędnych geograficznych niezbędnych do wizualizacji na mapach. Zastosowanie mechanizmu SCD2 w tych wymiarach gwarantuje, że dane historyczne będą analizowane zgodnie ze stanem faktycznym w momencie pomiaru.
- Wymiar `DimWeather` umożliwia skorelowanie liczby pieszych z temperaturą, opadami i zachmurzeniem w danym momencie.

Kluczowe miary, takie jak suma i średnia liczba pieszych, maksimum i minimum godzinowe, a także dynamika zmian, mogą zostać łatwo zdefiniowane w środowisku Power BI.


3.3 Proponowana struktura aplikacji raportowej - Power BI

Aplikacja analityczna zostanie podzielona na główny ekran podsumowujący oraz cztery dodatkowe zakładki analityczne, pozwalające na dogłębną analizę poszczególnych wymiarów.

3.3.1 Dashboard główny: Podsumowanie

Ekran startowy, przeznaczony do szybkiego monitorowania aktualnego stanu ruchu w mieście (przedstawiony na makiecie poniżej). Zbiera on najważniejsze wnioski z całego modelu:

- **Karty KPI:** Całkowita liczba pieszych (*Total Pedestrians*), liczba aktualnie aktywnych sensorów (*Active Sensors*) oraz średni dzienny ruch (*Avg. Daily Traffic*).
- **Wykres liniowy (Trend):** Zmiana liczby pieszych w ujęciu miesięcznym (*Pedestrian Traffic Trend*).
- **Analiza pogody (Wykres pierścieniowy):** Procentowy udział warunków atmosferycznych w całkowitym ruchu (*Weather Impact*), pokazujący ruch w dni słoneczne, pochmurne i deszczowe.
- **Ranking lokalizacji (Tabela):** Zestawienie topowych ulic (m.in. Flinders Street, Bourke Street) z ich udziałem procentowym w ogólnym ruchu (*Top Locations Ranking*).
- **Analiza czasu:** Interaktywny kalendarz (Heatmapa) wizualizujący natężenie ruchu w poszczególne dni miesiąca (*Traffic flow*), a także wykresy kolumnowe pokazujące rozkład godzinowy (*Daily Traffic*) oraz dzienny (*Traffic by Day of Week*).



Rysunek 4: Mockup głównego panelu analitycznego zaprojektowany w narzędziu Figma

Link do interaktywnego prototypu w Figma:

<https://www.figma.com/design/rZLknod8pGK3XvWo91M1KC/KM2?node-id=0-1&t=2QjGOJjqBianOZ>

3.3.2 Analiza szczegółowa: Lokalizacja i mapa przestrzenna

Zakładka rozszerzająca informacje z tabeli na ekranie głównym.

- **Mapa (Map visual):** Mapa Melbourne z punktami reprezentującymi sensory. Wielkość bąbelka oraz jego kolor będą zależne od wolumenu ruchu pieszego, co pozwoli na szybką identyfikację *hotspotów*.
- **Tabela szczegółowa:** Wykaz wszystkich lokalizacji z ich dokładnymi współrzędnymi i przypisanymi miarami agregującymi.

3.3.3 Analiza szczegółowa: Czas i sezonowość

Ekran dedykowany pogłębionej analizie rozkładu ruchu w czasie.

- **Mapa cieplna (Heatmap - Matrix):** Układ matrycowy, w którym wiersze reprezentują dni tygodnia, a kolumny godziny. Intensywność koloru wskaże dokładne godziny szczytu.

- **Wykres warstwowy (Area chart):** Analiza sezonowości, prezentująca zmiany ruchu w ujęciu kwartalnym i rocznym.

3.3.4 Analiza szczegółowa: Wpływ warunków atmosferycznych

Zakładka weryfikująca hipotezy o wpływie pogody.

- **Wykres punktowy (Scatter plot):** Zależność między dokładną temperaturą (TemperatureC) a liczbą pieszych, pozwalająca zaobserwować optymalne zakresy temperatur dla spacerów.
- **Wykres kolumnowy grupowany:** Średnia liczba pieszych w dniach z opadami (PrecipitationMm > 0) w porównaniu z dniami bezdeszczowymi.

3.3.5 Raport porównawczy lokalizacji

Interaktywne narzędzie pozwalające na bezpośrednie zestawienie ze sobą dwóch różnych obszarów miasta.

- **Dwa niezależne zestawy filtrów:** Pozwalające na wybranie Lokalizacji A oraz Lokalizacji B.
- **Wykresy wielokrotne (Small multiples):** Wykresy liniowe nakładające na siebie trendy dla obu lokalizacji w tym samym czasie.
- **Karty porównawcze:** Różnica w liczbie pieszych między wybranymi punktami wyrażona liczbowo i procentowo.